

Aula 1: Ambientes de Programação

Prof. Mauricio Duarte

Linguagens...

Linguagens de programação mais utilizadas em Big Data (R e Python);

Coleta de dados, limpeza e integração.







Leituras recomendadas...

LINGUAGEM R – POR QUE É HORA DE APRENDER?

http://datascienceacademy.com.br/blog/linguagem-r-por-que-e-hora-de-aprender/ (2018)

POR QUE CIENTISTAS DE DADOS ESCOLHEM PYTHON? (2019)

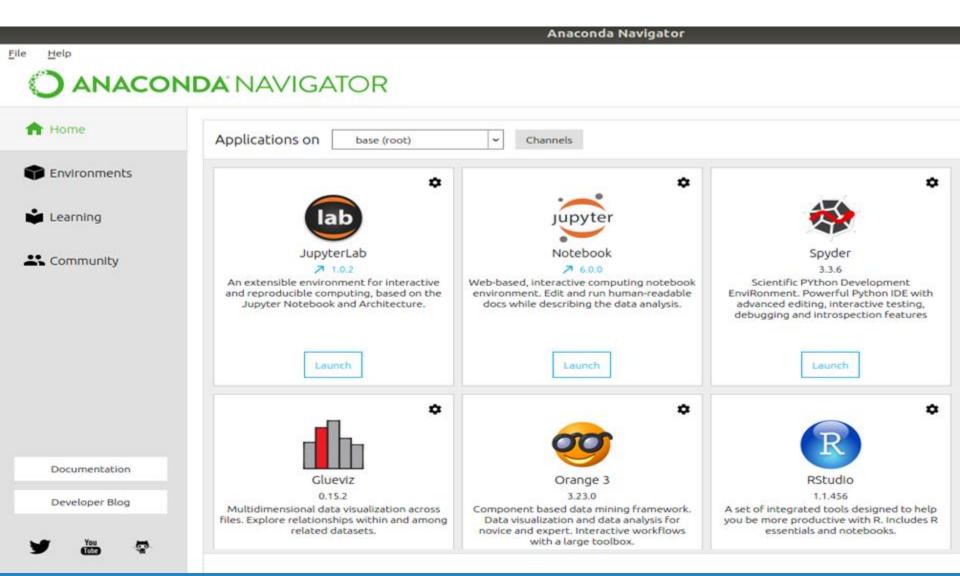
http://www.cienciaedados.com/por-que-cientistas-de-dados-escolhem-python/

R OU PYTHON PARA ANÁLISE DE DADOS?

http://www.cienciaedados.com/r-ou-python-para-analise-de-dados/ (2019)

Gerenciador de aplicações

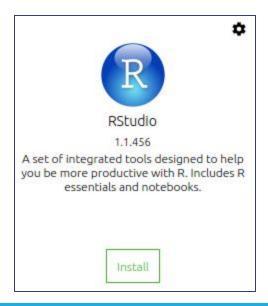
(https://www.anaconda.com/distribution/)

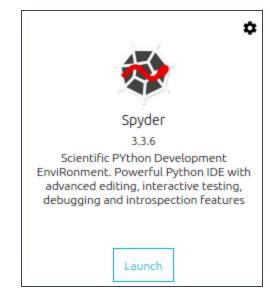


Ambientes de programação

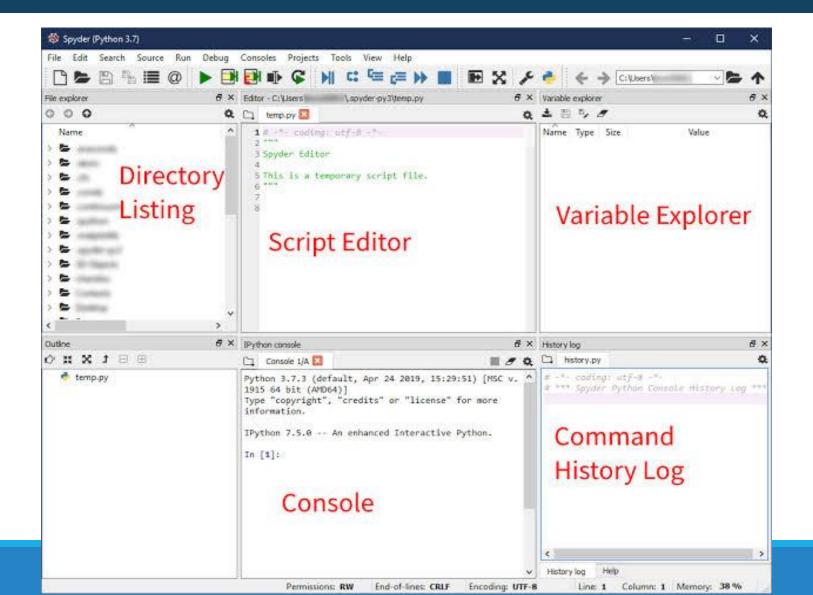
Anaconda - Spyder - Python

Anaconda - Rstudio - R

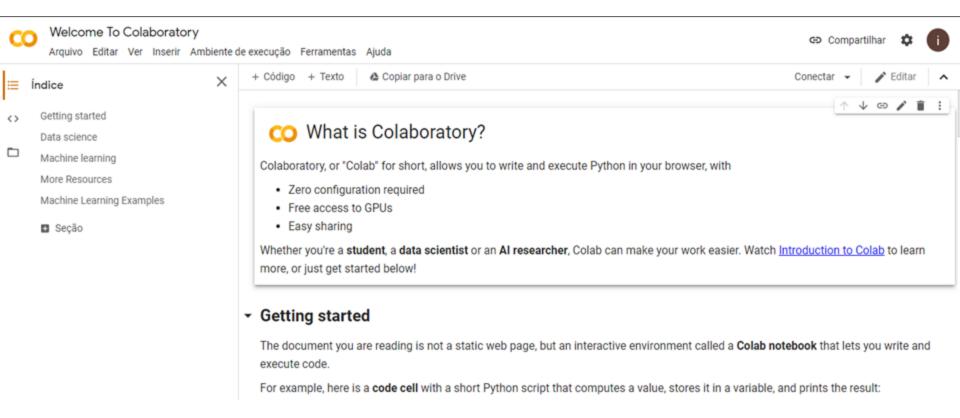




R Studio Online



Google Colab



https://www.alura.com.br/artigos/google-colab-o-que-e-e-como-usar

Pandas

Pandas é uma biblioteca para manipulação e análise de dados, escrita em Python.

Essa é a biblioteca perfeita para iniciar suas análises exploratórias de dados.

Ela permite ler, manipular, agregar e plotar os dados em poucos passos.

https://www.vooo.pro/insights/guia-de-acesso-rapido-ao-pandas/

Exemplo Pandas no Google Colab

```
import pandas as pd
base_de_dados = pd.read_csv("https://raw.githubusercontent.com/alura-cursos/formacao-data-science/master/movies.csv")
print(base de dados)
      movieId
                                                             genres
                     Adventure | Animation | Children | Comedy | Fantasy
                                       Adventure | Children | Fantasy
                                                    Comedy Romance
                                              Comedy | Drama | Romance
                                                             Comedy
                                  Action | Animation | Comedy | Fantasy
       193581
                                         Animation Comedy Fantasy
       193583
9738
       193585
9739
                                                              Drama
9740
       193587
                                                  Action | Animation
                                                             Comedy
9741
       193609
[9742 rows x 3 columns]
```

SciKit-sklearn

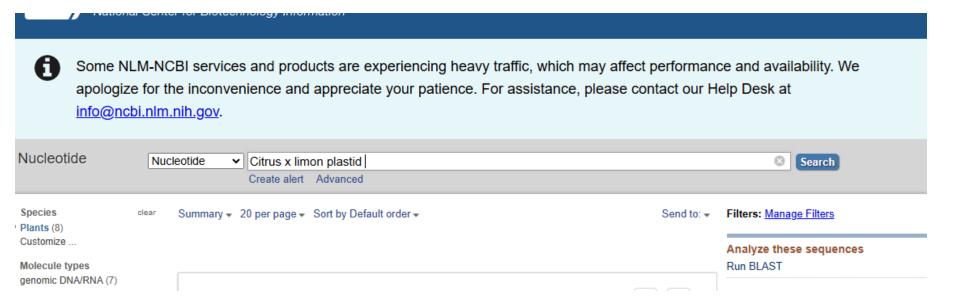
Scikit-sklearn é uma biblioteca Python amplamente usada para projetos que envolvem aprendizado de máquina.

Bases de Dados em Agricultura

- Genbank (https://www.ncbi.nlm.nih.gov/genbank/), o banco de dados de sequências genéticas, uma coleção anotada de todas as sequências de DNA disponíveis ao público;
- Base de Dados de Pesquisa Agropecuária

https://www.bdpa.cnptia.embrapa.br/consulta/busca;

GenBank....



Citrus x limon plastid Organismo Modelo



Na pesquisa.... 1º. Link...

- Filters activated: Plants. Clear all
- Citrus x limon plastid, complete genome
- 160,101 bp circular DNA

Accession: KY085897.1 GI: 1184801769

BioProject Protein Taxonomy

GenBank FASTA Graphics



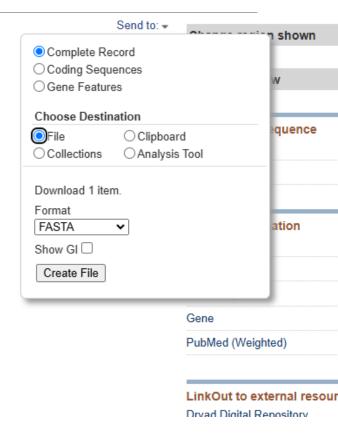
Baixando a base de dados FASTA...

FASTA -

Citrus x limon plastid, complete genome

GenBank: KY085897.1 GenBank Graphics

>KY085897.1 Citrus x limon plastid, complete genome TGGGCGAACGACGGGAATTGAACCCGCGCATGGTGGATTCACAATCCACTGCCTTGATCCACTTGGCTAC ATCCGCCCTCCGCTATTTACACAATTTTGAAATACAAAGATCTAAAATTCAACCATTGATTATTTTTGT TTATCTTATCTTACTTATGAAGAGCCAAATGAAGATCGAAGAGCAGAAAACTACAACCTTTCTATTGTCT CATAAAAATACTTAAACAAAAAAAAAAAAAATGAACTAAAAAACTAATAAAGAACCCCGATAAAGAAACCC GACTAAATAACGGATCAATACTGACGGGTCAGTATTGATCCGTTATTTTCAAAAACCCGCCTACACAAAG ACCAAAATCTTACCCATTTGTAGATGGGGCTTCAATAGCAGCTAGGTCTAGAGGAAGTTATGAGCATTA CTTGACTATCAACTACAGATTGGTTGAAATTGAAACCATTTAAGTTGAAAGCCATAGTGCTAATACCTAA AGCAGTGAACCAGATACCTACTACAGGCCAAGCAGCAGAAAATGTAAAGAACGAGAATTGTTGAAA CTAGCATATTGGAAGATCAATCGGCCAAAATAACCGTGAGCAGCTACGATATTATAAGTTTCTTCCTCTT GACCGAATCTGTAACCTGCATTAGCAGATTCATTTTCTGTGGTTTCCCTGATCAAACTAGAGGTTACCAA GGAACCATGCATAGCACTGAATAGGGAGCCGCCGAATACACCAGCTACGCCTAACATGTGGAATGGGTGC ATAAGGATGTTGTGCTCAGCCTGGAATACAATCATGAAATTGAAAGTACCAGAGATTCCTAGAGGCATAC CATCAGAAAAACTTCCTTGACCGATTGGGTAGATCAAGAAAACAGCAGTCGCTGCTGCAACAGGAGCTGA ATATGCAACAGCAATCCAAGGACGCATACCCAGACGGAAACTAAGTTCCCACTCACGACCCATGTAACAA GCTACACCAAGTAAGAAGTGTAGAACAATTAGCTCATAAGGACCGCCATTGTATAACCATTCATCAACGG ATGCCGCTTCCCATATCGGGTAAAAATGCAAACCTATAGCTGCAGAAGTAGGAATAATCGCACCAGAAAT



Atividade prática

Objetivos:

- 1.) Contar a quantidade de "A" (Adenina); "C" (Citosina); "T" (Timina) e "G" (Guanina)
- 2.) Emitir o percentual médio de cada uma delas.

Leituras Complementares...

Python - código para ler um arquivo no formato FASTA e transformá-lo em lista.

Disponível em:

https://gist.github.com/marcoscastro/89e8c66703d5067b9b3c

Trabalhando com Arquivos. Disponível em:

https://panda.ime.usp.br/pensepy/static/pensepy/10-Arquivos/files.html

Ler arquivos fasta no python e ignorar a primeira linha

Disponível em:

https://pt.stackoverflow.com/questions/236391/ler-arquivos-fasta-no-python-e-ignorar-a-primeira-linha/

Atividade Avaliativa – Aula 1

- Pesquisar como trabalhar com as bibliotecas pandas no uso de funções matemáticas básicas (média, mediana, moda e desvio padrão). Crie um pequeno guia de usuário. (Isso não é para entregar, ok).
- Faça um programa no Colab, que crie/gere uma lista capaz de armazenar 1000 idades de pessoas (valores entre 0 a 100).
 Mostre a idade media, a moda e a mediana. Considerando agora, que precisaremos ter apenas idades de adultos (>=21), faça com que todas as idades menores que 21 sejam substituídas pela media das idades >= 21 anos.